



Tema 6. Razonamiento Aproximado

Razonamiento con imprecisión: lógica borrosa

Daniel Manrique

dmanrique@fi.upm.es

D-2109

2019

Razonamiento con imprecisión

Lógica borrosa

1. Representación del conocimiento
2. Razonamiento en lógica borrosa
 - Controladores difusos

Bibliografía

■ Diapositivas (temas generales):

- Daniel Manrique, M. Carmen Suárez. Razonamiento con imprecisión: lógica borrosa. Apuntes y ejercicios. <http://oa.upm.es/46795/>, 2017.
- José Cuenca. Sistemas Inteligentes. Conceptos, técnicas y métodos de construcción. Facultad de Informática – Servicio de Publicaciones. Fundación General de la UPM. Madrid, 1997.
- G. J. Klir, B. Yuan. Fuzzy Sets and Fuzzy Logic. Theory and Applications. Prentice Hall PTR. New Jersey, 1995.

■ Temas específicos:


- J.M. Font, D. Manrique, J. Ríos. Evolutionary Construction and Adaptation of Intelligent Systems. Expert Systems With Applications, Vol. 37: 7711-7720, 2010.
- A. Carrascal, A. Díez, J.M. Font, D. Manrique. Evolutionary Generation of Fuzzy Knowledge Bases for Diagnosing Monitored Railway Systems. Proceedings of 22nd International Congress Condition Monitoring and Diagnostic Engineering Management, pp. 191-198, 2009. San Sebastián, España.
- J. Couchet, J.M. Font, D. Manrique. Using Evolved Fuzzy Neural Networks for Injury Detection from Isokinetic Curves. Proceedings of 28th International Conference on Innovative Techniques and Applications of Artificial Intelligence, pp. 225-238, 2008. Cambridge, UK.
- A. Carrascal, D. Manrique, J. Ríos, C. Rossi. Evolutionary Local Search of Fuzzy Rules through a novel Neuro-Fuzzy Encoding Method. International Journal of Evolutionary Computation, Vol. 11(4): 439-461, 2003.

Representación del conocimiento

1. Borrosidad, vaguedad, imprecisión.
2. Conjuntos borrosos.
3. Operaciones con conjuntos borrosos.

Imprecisión

- La lógica borrosa permite representar conjuntos con **fronteras no precisas**.
- La afirmación "x pertenece a A" no es cierta o falsa, sino que medible mediante una posibilidad en $[0,1]$.
- Permite manejar la vaguedad o imprecisión.
 - "Día caluroso": la frontera entre caluroso y templado no es exacta.



- ¿Se puede suponer que si hay 30°C el día es caluroso, pero **si hay 29.9°C, ¿entonces ya no lo es?**

Imprecisión e incertidumbre

- **Imprecisión**: vaguedad, fronteras mal definidas.
- **Incetidumbre**: si lanzamos un dado hay seis sucesos (precisos), pero se desconoce qué saldrá.
- Aplicaciones de la lógica borrosa:
 - Sistemas basados en el conocimiento.
 - **Control difuso.**
 - Reconocimiento de patrones.
 - Proceso de encaje en marcos.


Representación del conocimiento

1. Borrosidad, vaguedad, imprecisión.
2. **Conjuntos borrosos.**
3. Operaciones con conjuntos borrosos.

Conjuntos borrosos


- Conjunto borroso: aquél en donde la pertenencia de los elementos se define mediante una **función de pertenencia** o **función de distribución de posibilidad**.
 - $\mu_A: X \rightarrow [0,1]$.
 - El conjunto borroso A tiene una función de pertenencia $\mu_A(x)$ que asigna a cada valor $x \in X$ un número entre 0 (no pertenece) y 1 (sí pertenece).
 - Los valores intermedios representan pertenencia parcial.

- Ejemplo: $\mu_{\text{caluroso}}: T^a \rightarrow [0,1]$:




Distribuciones típicas

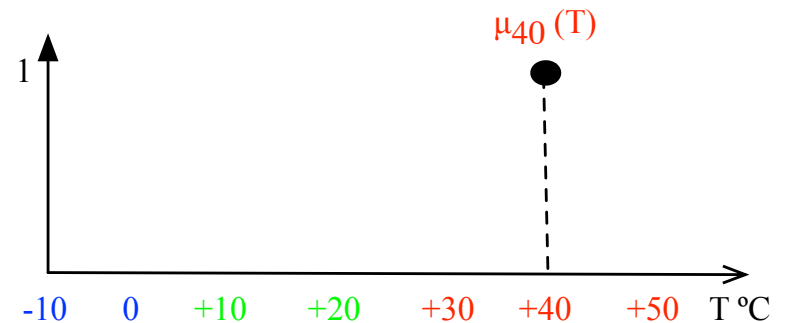
- Trapezoidales:



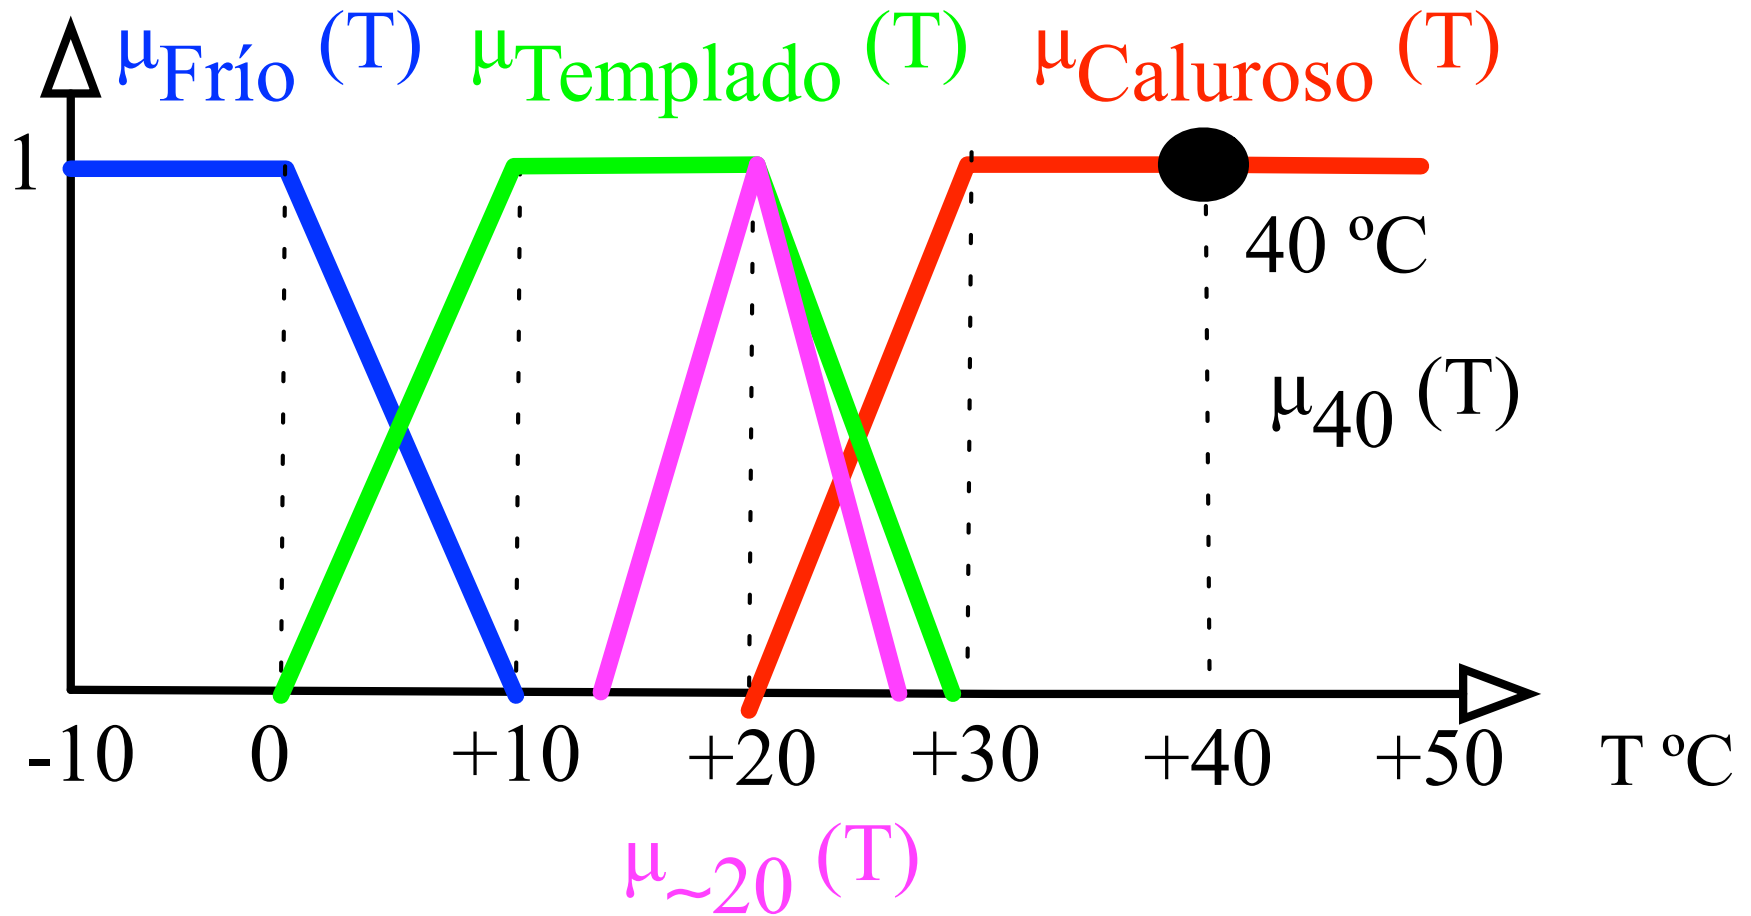
- Triangulares:



- Nítidas:



Ejemplo



Representación del conocimiento

1. Borrosidad, vaguedad, imprecisión.
2. Conjuntos borrosos.
3. Operaciones con conjuntos borrosos.

Composición de fórmulas


- A partir de la cuantificación de la posibilidad de que sea cierta "x es p" expresado como $\mu_p(x)$:
 - x es p y q: $\mu_{p \wedge q}(x)$.
 - x es p ó q: $\mu_{p \vee q}(x)$
 - x no es p: $\mu_{\neg p}(x)$
 - Si x es p, entonces x es q: $\mu_{p \rightarrow q}(x)$
- Generalización a n dimensiones:
 - $\mu_{p \wedge q}(x_1, x_2, \dots, x_n)$, $\mu_{p \vee q}(x_1, x_2, \dots, x_n)$, etc.

Extensión cilíndrica

- Para componer dos funciones, deben estar **referidas a las mismas variables**:
 - No es posible componer x es p e y es q :
$$\mu_p(x) \wedge \mu_q(y)$$
- Para ello se calcula la extensión cilíndrica de $\mu_p(x)$ con y , y la extensión cilíndrica de $\mu_q(y)$ con x para obtener $\mu_p(x,y)$ y $\mu_q(x,y)$.
 - Entonces es posible: $\mu_{p \wedge q}(x,y)$
- La extensión cilíndrica de $\mu_p(x_1, x_2, \dots, x_n)$ con y es $\mu_p(x_1, x_2, \dots, x_n, y)$ tal que cumple:
$$\forall y \mu_p(x_1, x_2, \dots, x_n, y) = \mu_p(x_1, x_2, \dots, x_n)$$

Extensión cilíndrica. Ejemplo

- Se desea representar que la tarifa de un taxi es barata cuando la carrera es corta.
 - Se tiene $\mu_{\text{corta}}(\text{distancia})$ y $\mu_{\text{barato}}(\text{precio})$.
 - Se desea calcular $\mu_{\text{corta} \wedge \text{barato}}(\text{distancia, precio})$



t-Norma, t-Conorma, negación

- Se manejan las siguientes funciones:
 - t-norma:
 - Conjunción (lógica), intersección (conjuntos)
 - $T(x,y). \mu_{p \wedge q}(x) = T(\mu_p(x), \mu_q(x))$
 - t-conorma:
 - Disyunción (lógica), unión (conjuntos)
 - $S(x,y). \mu_{p \vee q}(x) = S(\mu_p(x), \mu_q(x))$
 - Negación:
 - $N(x). \mu_{\neg p}(x) = N(\mu_p(x)).$

Funciones T: t-normas

- Representa la **conjunción** o **intersección**.
- $\forall x, y, z$ distribuciones de posibilidad. Propiedades:
 1. $T(x, 1) = x$ (elemento neutro)
 2. $x \leq y \rightarrow T(x, z) \leq T(y, z)$ (monotonía)
 3. $T(x, y) = T(y, x)$ (conmutativa)
 4. $T(x, T(y, z)) = T(T(x, y), z)$ (asociativa)
- Ejemplos:
 - $T(x, y) = \min(x, y)$ (mínimo)
 - $T(x, y) = P(x, y) = x \cdot y$ (producto)
 - $T(x, y) = W(x, y) = \max(0, x + y - 1)$ (Lukasiewicz)
 - $T(x, y) = Z(x, y) = x$ si $y = 1$; y si $x = 1$; 0 resto (drástica)

Funciones S: t-conormas

- Representa la disyunción.
- $\forall x, y, z$ distribuciones de posibilidad. Propiedades:
 1. $S(x,0) = x$ (elemento neutro)
 2. $x \leq y \rightarrow S(x,z) \leq S(y,z)$ (monotonía)
 3. $S(x,y) = S(y,x)$ (conmutativa)
 4. $S(x,S(y,z)) = S(S(x,y),z)$ (asociativa)
- Ejemplos:
 - $S(x,y) = \text{máx}(x,y)$ (máximo)
 - $S(x,y) = P'(x,y) = x+y-x \cdot y$ (suma-producto)
 - $S(x,y) = W'(x,y) = \text{mín}(1, x+y)$ (Lukasiewicz)
 - $S(x,y) = Z'(x,y) = x$ si $y=0$; y si $x=0$; 1 resto (drástica)

Funciones de negación

- Debe cumplir $\forall x$ función de distribución de posibilidad:
 1. $N(0) = 1; N(1) = 0$ (condiciones frontera)
 2. $x \leq y \rightarrow N(x) \geq N(y)$ (inversión de monotonía)
- Ejemplos:
 - $N(x) = (1-x)$
 - $N(x) = (1-x^2)^{1/2}$

Implicación difusa (I)

- Se han visto las operaciones:
 - $T(x,y)$, $S(x,y)$ y $N(x)$
 - Conjuntos:
 - Intersección, unión y complementario
 - Lógica:
 - Conjunción, disyunción y negación
- En lógica borrosa se define la implicación a través de la función binaria $J(x,y)$.

$$\mu_{p \rightarrow q}(x) = J(\mu_p(x), \mu_q(x))$$

Implicación difusa (II)

- De la lógica clásica, se tiene que:
 - $A \rightarrow B = \neg A \vee B$
 - $J(x,y) = S(N(x),y)$.
- Tomando $N(x) = 1-x$, se tiene:
 - Con $S(x,y) = \text{máx}(x,y)$ $J(x,y) = \text{máx}(1-x,y)$
 - Con $S(x,y) = P'(x,y) = x+y-x \cdot y$ $J(x,y) = 1-x+x \cdot y$
 - $S(x,y) = W'(x,y) = \text{mín}(1, x+y)$ $J(x,y) = \text{mín}(1, 1-x+y)$
 - $S(x,y) = Z'(x,y) = x$ si $y=0$; y si $x=0$; 1 resto
 $J(x,y) = y$ si $x=1$; $1-x$ si $y=0$; 1 resto
- **$J(x,y) = \text{mín}(x,y)$. Implicación de Mamdani**

Índice

1. Representación del conocimiento con lógica borrosa
2. Razonamiento en lógica borrosa
 - Controladores difusos

Modus ponens generalizado

- Modus ponens:
 - Regla: Si X es A, entonces Y es B
 - Hecho: X es A.

 - Conclusión: Y es B

- En lógica borrosa se puede generalizar al no requerir X es A, sino X es A':
 - **Modus ponens generalizado:**
 - Regla: Si X es A, entonces Y es B
 - Hecho: X es A'

 - Conclusión: Y es B'

 - La función de posibilidad de $\mu_{B'}$ se calcula con RCI.

Regla composicional de inferencia

$$\mu_{B'}(y) = \sup_{x \in X} \{T(\mu_{A'}(x), \mu_{A \rightarrow B}(x, y))\}$$

Inferencia difusa con RCI

- Datos: X es A: $\mu_A(x)$, Y es B: $\mu_B(y)$, X es A': $\mu_{A'}(x)$
- Objetivo: cálculo $\mu_{B'}(y)$
- 1. Calcular $\mu_{A \rightarrow B}(x, y)$ a partir de $\mu_A(x)$ y $\mu_B(y)$
 - Es necesario realizar las **extensiones cilíndricas**: $\mu_A(x)$ con y , $\mu_B(y)$ con x
 - Se emplea para la implicación cualquier función $J(x, y)$. E.g. Zadeh: $J(x, y) = \max(1-x, y)$.
- 2. Calcular $T(\mu_{A'}(x), \mu_{A \rightarrow B}(x, y))$.
 - Se realiza la **extensión cilíndrica** de $\mu_{A'}(x)$ con y .
 - Se emplea una T-norma. $T(x, y) = \min(x, y)$.
- 3. **Calcular el supremo** en x de $T(\mu_{A'}(x, y), \mu_{A \rightarrow B}(x, y))$, que está en función de x e y .
 - Se obtiene la distribución de posibilidad sobre la dimensión y : $\mu_{B'}(y)$, es decir, las posibilidades de y es B' .

Motor de inferencia borroso

- Base de conocimiento:
 - R1: Si X es A_1 , entonces Y es B_1 .
 - R2: Si X es A_2 , entonces Y es B_2 .
 -
 - Rn: Si X es A_n , entonces Y es B_n .
 - Hecho: X es A'
- Se aplica la RCI a cada regla, obteniendo:
 - $\mu_{B1'}(Y), \mu_{B2'}(Y), \dots, \mu_{Bn'}(Y)$.
- A partir de las distribuciones anteriores, se calcula la distribución final y es B' mediante la t-conorma S.
 - $\mu_{B'}(Y) = S(\mu_{B1'}(Y), \mu_{B2'}(Y), \dots, \mu_{Bn'}(Y))$.

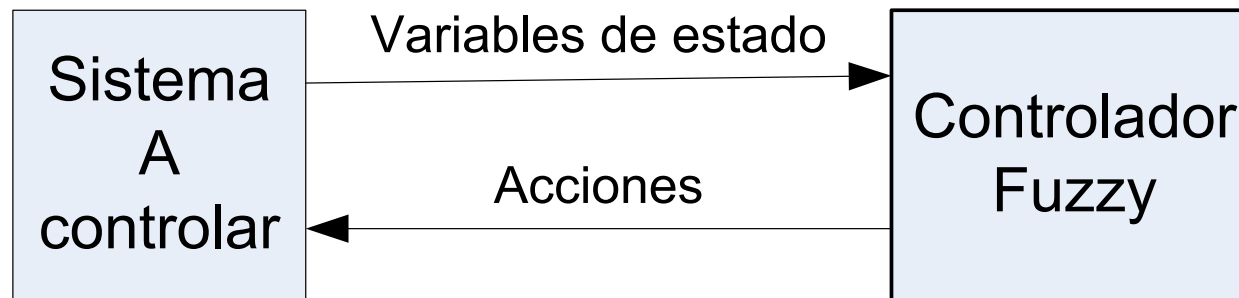
Índice

1. Representación del conocimiento con lógica borrosa
2. Razonamiento en lógica borrosa
 - Controladores difusos

Controladores difusos

- Se emplean para controlar sistemas **inestables**.
- El control tiene por objeto garantizar una salida en el sistema a pesar de las **perturbaciones** que le afectan.
- Ejemplos:
 - Sistemas de **navegación**.
 - Sistemas de **climatización**.
 - Sistemas de **ventilación** (túneles, garajes).

Esquema control difuso




- **Variables de estado:**
 - s_1, s_2, \dots, s_n : estado del sistema. **Temperatura.**
 - e_1, e_2, \dots, e_n : desvíos (error) con respecto al valor de referencia. Temperatura con respecto a 20 °C: **ΔT^a**
 - $\Delta e_1, \Delta e_2, \dots, \Delta e_n$: tendencia del error: **T^a / t**
- **Acciones:**
 - v_1, v_2, \dots, v_m : cambios a realizar en los actuadores. Administrar la potencia de la caldera.

Modelo de control difuso

- Los valores de las variables de estado y acciones pueden ser etiquetas lingüísticas (valores cualitativos) que son representados por funciones de posibilidad:

$$R_1: \text{Si } e=A_1, \dots, \Delta e=B_1, \dots, \text{ entonces } v=C_1$$

- En lo que sigue, se utilizarán reglas del tipo:
 - Si $e=A$, $\Delta e=B$, entonces $v = C$
 - Cada valor de e , Δe y v son etiquetas lingüísticas con su correspondiente función de posibilidad. Por ejemplo, para e :



Por ejemplo:
Si $e = NB$

Notación

- Dada la regla: Si $e=A$ y $\Delta e=B$, entonces $v = C$
 - A , B y C son funciones de posibilidad:
 - $\mu_A(e)$, $\mu_B(\Delta e)$, $\mu_C(v)$
 - La notación será la siguiente:
 - Si $e = A(e)$ y $\Delta e=B(\Delta e)$, entonces $v = C(v)$
 - Un controlador difuso posee una **base de conocimiento** de reglas del tipo:
 - R1: Si $e = A_1(e)$ y $\Delta e=B_1(\Delta e)$, entonces $v = C_1(v)$
 - R2: Si $e = A_2(e)$ y $\Delta e=B_2(\Delta e)$, entonces $v = C_2(v)$
 - ...
 - Rn: Si $e = A_n(e)$ y $\Delta e=B_n(\Delta e)$, entonces $v = C_n(v)$
-
- En un momento el estado del sistema es:
 - $e = A(e)$ y $\Delta e=B(\Delta e)$.
 - Tras un proceso de inferencia, el controlador responde para mantener el equilibrio: $v = C(v)$

Regla composicional de inferencia

- El proceso de inferencia emplea la regla composicional de inferencia:

$$\mu_{B'}(y) = \sup_{x \in X} \{T(\mu_{A'}(x), \mu_{A \rightarrow B}(x, y))\}$$

- y es v . La acción a tomar.
- x es bidimensional: e y Δe .
- $\mu_{B'}(y) = C'(v)$. Distrib. de posib. de la acción a tomar.
- $\mu_{A'}(x) = A'(e) \wedge B'(\Delta e)$. Estado actual del sistema.
- $\mu_{A \rightarrow B}(x, y) = R_i: A_i(e) \wedge B_i(\Delta e) \rightarrow v = C_i(v)$

$$C'_i(v) = \sup_{e, \Delta e} \{T(A'(e) \wedge B'(\Delta e), A_i(e) \wedge B_i(\Delta e) \rightarrow C_i(v))\}$$

Inferencia en controladores (I)

- $T(x,y) = \min(x,y)$.
- $J(x,y) = \min(x,y)$. Mamdani.

$$C'_i(v) = \sup_{e, \Delta e} \left\{ T(A'(e) \wedge B'(\Delta e), A_i(e) \wedge B_i(\Delta e) \rightarrow C_i(v)) \right\}$$

$$C'_i(v) = \sup_{e, \Delta e} \left\{ \min(\min(A'(e), B'(\Delta e)), \min(\min(A_i(e), B_i(\Delta e)), C_i(v))) \right\}$$

Asociatividad:

$$C'_i(v) = \min \left(\min \left(\sup_e \left\{ \min(A'(e), A_i(e)) \right\}, \sup_{\Delta e} \left\{ \min(B'(\Delta e), B_i(\Delta e)) \right\} \right), C_i(v) \right)$$

Inferencia en controladores (II)

Antecedente
regla

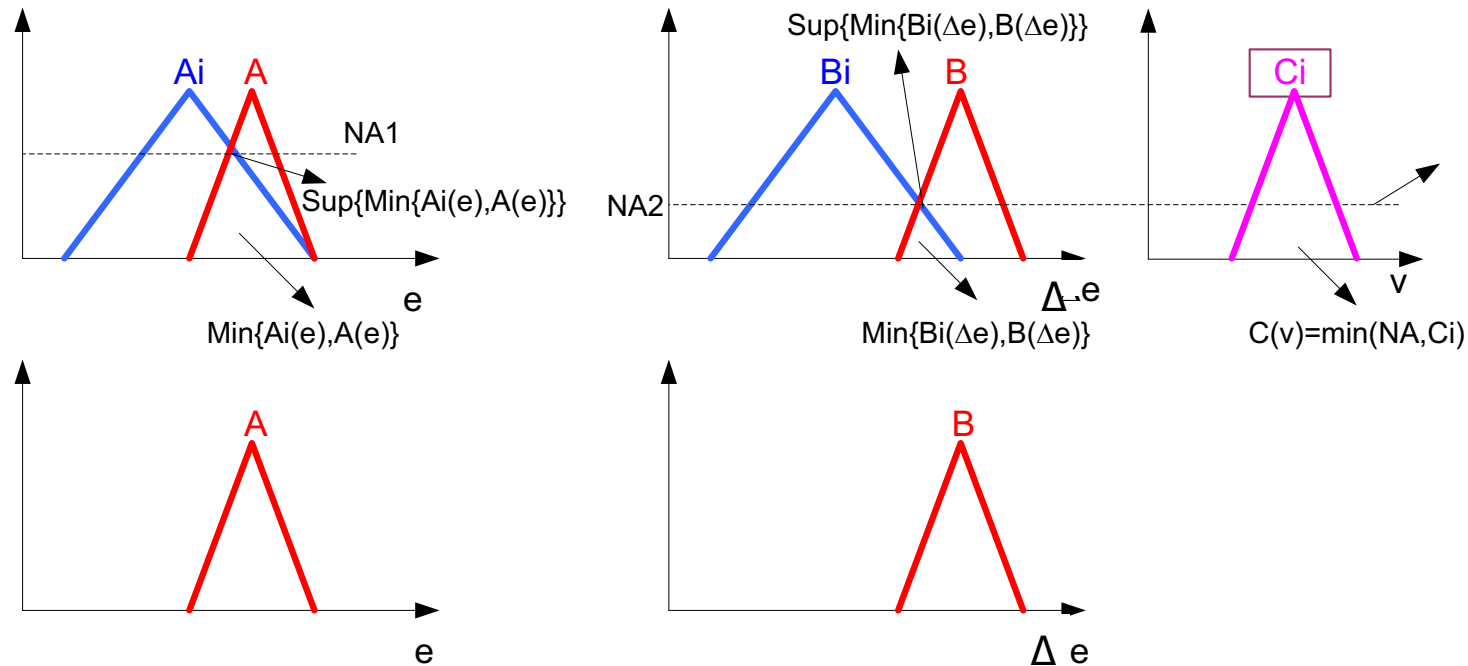
Antecedente
regla

$$C'_i(v) = \min \left(\min \left(\sup_e \{ \min(A'(e), A_i(e)) \}, \sup_{\Delta e} \{ \min(B'(\Delta e), B_i(\Delta e)) \} \right), C_i(v) \right)$$

$$C'_i(v) = \min(\min(NA_{i1}, NA_{i2}), C_i(v))$$

$$C'_i(v) = \min(NA_i, C_i(v))$$

Interpretación geométrica



Procedimiento general


- Dada una base de conocimiento:
 - R1: Si $e = A_1(e)$ y $\Delta e = B_1(\Delta e)$, entonces $v = C_1(v)$
 - ...
 - Rn: Si $e = A_n(e)$ y $\Delta e = B_n(\Delta e)$, entonces $v = C_n(v)$
 - Hecho: $e = A'(e)$ y $\Delta e = B'(\Delta e)$.
 - Objetivo: $v = C'(v)$
- **Procedimiento:**
 1. Para cada regla R_i , se obtiene:
 - $NA_i = \min\{\text{Sup}_e[\min(A'(e), A_i(e))], \text{Sup}_{\Delta e}[\min(B'(\Delta e), B_i(\Delta e))]\}$
 - La distribución del consecuente $C'_i(v) = \min(NA_i, C_i(c))$
 2. Se obtiene la unión: de los $C'_i(v)$ de las reglas que se disparan
 - $C'(v) = \cup_i \{C'_i(v)\} = \max_i \{C'_i(v)\}$
 3. *Desborrocificación de $C'(v)$*

Desborrocificación

Método del centro de gravedad

- Cálculo de la proyección en el eje x del centro de gravedad de la distribución.
- Se debe muestrear **suficientemente fino** para cubrir adecuadamente la función.
- Un muestreo excesivo exige gran carga computacional.
- Para generalizar $\mu_A(x) = \mu_B(y)$

$$g = \frac{\sum_{i=1}^N x_i \cdot \mu_A(x_i)}{\sum_{i=1}^N \mu_A(x_i)}$$



Desborrocificación

Método Σ_{cuenta}

- Objetivo:

- Dado un conjunto de distribuciones de posibilidad $\mu_{B1}(x), \mu_{B2}(x), \dots, \mu_{Bn}(x)$
- Encontrar qué $\mu_{Bi}(x)$ *se parece más* a una dada $\mu_A(x)$.

- La Σ_{cuenta} es una medida proporcional al área de la distribución.

- Se basa en la discretización de la función de distribución.

$$\Sigma_{\text{cuenta}}(A) = \sum_{i=1}^N \mu_A(x_i)$$

- El método elige como *más parecido* a $\mu_A(x)$ aquella $\mu_{Bi}(x)$ que *máximiza*:

$$\Sigma_{\text{cuenta}}(B_i/A) = \frac{\Sigma_{\text{cuenta}}(A \wedge B_i)}{\Sigma_{\text{cuenta}}(B_i)}$$